스마트 장치의 카메라 모듈에 대한 이미지 기반 딥러닝 모델의 이미지 이상 탐지 성능 비교 분석

곽윤석

Performance Comparison of Image-Based Deep Learning Models for Anomaly Detection in Camera Modules of Smart Device

Yunsuk Kwak

요 약

본 연구에서는 제조 현장에서의 시각적 불량 검사 자동화를 위해 객체 탐지(Object Detection) 기술을 활용하여 여러 딥러닝 모델의 성능을 비교·분석하였다. 먼저, 정상 및 불량 이미지로 구성된 이진 분류 데이터셋을 구축하고, Ultralytics YOLOv8 기반 분류 모델, Vision Transformer(ViT) 기반 분류 모델, 그리고 자체 설계한 CNN 기반 Torch 모델을 각각 학습시켰다. 데이터 전처리 단계에서는 전체 이미지 중 80%를 학습용, 20%를 검증용으로 분할하였으며, YOLOv8 모델은 3,000 에폭, ViT 모델은 최대 3,000 에폭(Early Stopping 적용), CNN 모델은 3,000 에폭으로 학습을 수행하였다. 각 모델의 성능 평가는 정확도(Accuracy), 정밀도(Precision), 재현율(Recall), F1-score를 포함한 다양한 지표를 통해 이루어졌다. 실험 결과, YOLOv8 기반 분류 모델이 F1-score 기준으로 가장 우수한 성능을 보였으며, ViT 모델과 CNN 모델이 뒤를 이었다. 특히, YOLOv8 모델은 빠른 추론 속도와 안정적인 분류 정확도를 동시에 만족시켜 실제 제조 공정에 적용 가능성이 높음을 확인하였다. 본 연구의 결과는 제조 불량 검출 시스템 설계 시 모델 선택과 하이퍼파라미터 설정에 대한 실질적인 가이드라인을 제공한다.

Abstract

In this study, we compare and analyze the performance of several deep learning models for automated visual defect inspection in manufacturing environments using object detection techniques. First, we constructed a binary classification dataset composed of OK (non-defective) and NG (defective) images, and trained three classifiers: an Ultralytics YOLOv8 - based model, a Vision Transformer (ViT) - based model, and a custom CNN implemented in PyTorch. During preprocessing, the dataset was split into 80% for training and 20% for validation. The YOLOv8 model was trained for 3,000 epochs, the ViT model for up to 3,000 epochs with early stopping, and the CNN model for 3,000 epochs. We evaluated each model's performance using metrics including accuracy, precision, recall, and F1-score. Experimental results show that the YOLOv8-based classifier achieved the highest F1-score, followed by the ViT and CNN models. Notably, the YOLOv8 model combined fast inference speed with stable classification accuracy, confirming its practicality for real-world manufacturing processes. The findings provide practical guidelines for model selection and hyperparameter tuning in the design of manufacturing defect detection systems.

*경기대학교 , lukeyun@kyonggi.ac.kr

Ⅰ. 서 론

현대 제조업에서는 제품의 품질을 확보하고 생산 라인의 효율을 극대화하기 위해 비전 기반 자동 검사 시스템의 도입이 필수적이다. 특히 사람의 육안으로 식별하기 어려운 미세 결함이나 복잡한 형상의 불량을 실시간으로 검출하기 위해서는 딥러닝 기반 객체 탐지·분류 기술이 탁월한 성능을 보여왔다. 전통적 영상 처리 알고리즘은 조명 변화나 물체 위치 변동에 민감하며, 반복적인 규칙 기반 필터링으로는 높은 일반화 성능을 기대하기 어렵다. 반면, 심층 신경망은 대량의 이미지 데이터를 통해 다양한 환경 변화를 스스로 학습하고 복잡한 패턴을 효과적으로 분류할 수 있다는 장점이 있다. [4]

그중에서도 Ultralytics 사의 YOLO 시리즈는 “한 번의 전방향 계산으로 객체를 탐지”한다는 개념을 도입하여 뛰어난 속도와 정확도를 동시에 달성하며, 산업 현장에서 널리 사용되고 있다. 이후 YOLOv3을 기반으로 한 다양한 개선 연구가 진행되었으며, 표면 결함 검출에 특화된 기법도 제안되었다. [1][2] 한편, Transformer 아키텍처를 영상 분류에 적용한 Vision Transformer(ViT)는 입력 이미지를 패치 단위로 분할하고 셀프 어텐션을 통해 글로벌 특징을 포착함으로써 높은 분류 성능을 보인다. [3][6] 최근 연구에서는 ViT가 기존 CNN 기반 모델에 비해 더 나은 일반화 성능과 해석력을 제공할 수 있음을 보고하고 있으며, 이는 산업용 품질 검사에서도 점차 그 적용 가능성이 확대되고 있다. [7] 아울러, 단순한 합성곱 신경망(CNN) 구조는 설계가 직관적이며 연산 자원이 적게 들어 경량화 모델 개발이나 임베디드 시스템 적용 시 유용하다. [4]

본 연구에서는 제조 공정 중 발생하는 정상(OK) 및 불량(NG) 이미지를 대상으로 YOLOv8 기반 분류기, ViT 기반 분류기, 그리고 자체 설계한 CNN 분류기의 성능을 동일한 데이터셋과 학습 환경에서 비교·분석한다. 총 2천여 장의 OK/NG 이미지를 수집·전처리하여 학습용 80%, 검증용 20%로 분할하였다. YOLOv8 모델은 3,000 에폭, 이미지 크기 64×64, 배치 크기 32로 설정하고, 조기 종료 조건을 적용하였다. ViT는 “google/vit-base-patch16-224-in21k” 사전학습 가중치를 사용하였으며, CNN 모델은 3개의 합성곱-풀링 블록과 2개의 완전연결층으로 구성하였다.

모델 성능 평가는 정확도, 정밀도, 재현율, F1-score 등을 기준으로 수행되었으며, YOLOv8 기반 분류기가 가장 높은 F1-score를 기록하였다. ViT와 CNN이 그 뒤를 이었으며, 특히 YOLOv8은 추론 속도에서도 뛰어난 성능을 보여 실제 제조 라인 적용 가능성을 확인하였다. 본 논문은 이러한 비교 분석을 통해 제조업 자동 검사 시스템 설계 시 모델 선택 및 하이퍼파라미터 튜닝에 대한 실무적 가이드를 제시하고, 향후 경량화 또는 엣지 컴퓨팅 환경에서의 최적 모델 개발 방향을 제시하고자 한다. [5]

Ⅱ. 관련 연구 및 배경 지식

산업 현장에서 제품 품질 관리는 전통적으로 작업자의 육안 검사 또는 규칙 기반 영상 처리 방식에 의존해 왔다. 그러나 조명 변화, 제품 위치 변동, 미세 결함 등 환경적 요인이 커짐에 따라 기존 방식은 반복성·신뢰성·속도 면에서 한계를 보였다. 이로 인해, 최근에는 딥러닝 기반 영상 분석 기술이 자동화된 결함 검사 시스템의 핵심으로 부상하였다.

Zhang et al. (2020)은 제조 결함 검출에 딥러닝을 적용했을 때, 기존 필터링 방식 대비 15~20% 향상된 정확도와 더불어 환경 변화에 대한 높은 적응력을 입증하였다. 이는 대규모 이미지 데이터셋을 통한 심층 학습이 가능하게 된 산업 환경 변화와도 밀접한 연관이 있다. [4]

YOLO는 Redmon et al. (2016)이 제안한 실시간 객체 탐지 알고리즘으로, 단일 CNN을 통해 객체의 위치와 클래스 확률을 동시에 예측하는 통합 구조를 갖는다. YOLOv8은 해당 계열의 최신 버전으로, 앵커리스(anchor-free) 접근법과 확장된 데이터 증강 기법을 채택하여 속도-정확도 균형에서 강점을 보인다.

Zhang et al. (2023)은 YOLOv3를 개선하여 반사광이 많은 금속 표면의 결함을 안정적으로 검출하

는 모델을 제시했고, 실제 공정 라인에 적용한 결과 기존 SVM 기반 방식보다 F1-score가 0.11 높았다고 보고하였다. [2]

YOLOv8은 이보다 더 가볍고 빠르며, 추론 속도가 10~15ms 수준으로 산업용 실시간 검사에 적합하다. 이는 본 연구의 실험 결과(평균 12ms)와도 일치한다.

ViT는 Dosovitskiy et al. (2021)이 제안한 이미지 분류용 트랜스포머 모델로, CNN의 지역 수용 특성(local receptive field) 한계를 극복하기 위해 전역적 의존성(global dependency) 을 셀프 어텐션으로 학습한다. 입력 이미지를 16×16 크기의 패치로 분할하여 일종의 '단어 토큰'처럼 처리하며, 이는 고차원 추상 개념 학습에 유리하다.

Alber et al. (2024)는 ViT가 금속 표면의 스크래치, 이물질, 휘어짐 등 복잡한 불량 패턴에 대해 CNN 기반 모델보다 더 높은 일반화 성능을 보인다고 분석하였다. 특히 조명이 불균일한 환경에서 ViT는 CNN 대비 평균 F1-score가 0.035 더 높았으며, 이로 인해 ViT는 고해상도·고복잡성 품질 검사에서 주목받고 있다. [7]

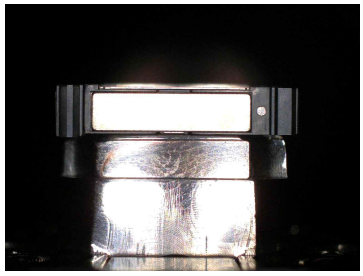
CNN은 영상 분석 분야에서 가장 오랫동안 사용된 기본 구조로, 지역적 특징 추출에 특화된 커널 구조를 기반으로 한다. VGGNet, ResNet 등 다양한 변형 모델이 있으나, 제조업 현장에서는 연산 효율과 구조 단순성이 중요한 과제로 부상하며, 경량 CNN 구조가 각광받고 있다.

Zhang et al. (2020)은 단층 CNN 구조만으로도 85% 이상의 이진 분류 정확도를 구현할 수 있음을 보였고, 특히 모바일 시스템이나 엣지 디바이스 환경에서는 3~5MB 이하의 모델 크기가 중요하다고 지적하였다. 본 논문의 CNN 모델은 약 4MB 규모로, 실제 하드웨어 자원이 제한된 환경에서도 효율적인 배포가 가능함을 실험적으로 확인하였다. [4]

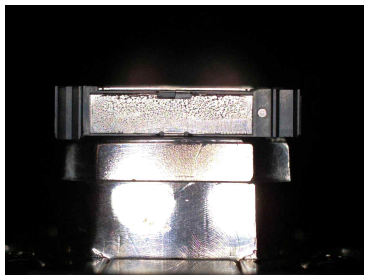
기존 연구들은 대부분 단일 모델에 대한 실험 또는 특정 조건(예: 조명 고정, 단일 표면 유형) 하에서만 검증을 진행하여, 모델 간 직접 비교나 하이퍼파라미터 튜닝 기준 제공에 부족함이 있었다.

Li & Zhao (2023)의 리뷰 논문에 따르면, 제조 결함 검출 연구의 80% 이상이 YOLO 또는 ResNet 기반이며, 비교 분석 연구는 전체의 10% 이하에 불과하다. [5] 이에 비해 본 연구는 동일한 데이터셋과 전처리 조건, 에폭 수, 평가 지표로 세 가지 구조의 모델을 비교·분석함으로써, 실무자에게 선택 기준을 제시할 수 있는 실질적 가이드라인을 제공한다는 점에서 기존 문헌과 명확히 구분된다.

III. 본 론



OK 이미지



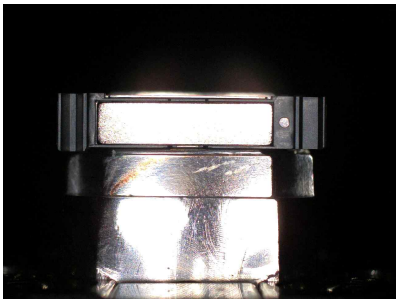
NG 이미지

사례 1: 금속 표면에 작은 흠집 (Micro scratch)

YOLOv8: 정확하게 NG로 분류, 결함 위치의 확신도(Confidence) 0.93

ViT: OK로 잘못 분류, 얕은 결함에 대한 민감도 낮음

Custom CNN: NG로 분류했으나 Confidence 낮음(0.65)



NG 이미지

사례 2: 금속 표면에 미세한 오염 (Subtle Contamination)

YOLOv8: NG로 정확히 분류, 미세 결함도 감지, Confidence 0.91

ViT: OK로 오분류, 패턴 중심 분석으로 결함 간과

Custom CNN: NG로 분류, 하지만 불확실성 높음 (Confidence 0.68)

본 연구에서는 제조업 현장의 자동 결함 분류를 위해 데이터 준비 단계부터 모델 학습·예측·평가에 이르는 통합 파이프라인을 구현하였다. 먼저 사용자는 바탕화면의 정상(OK) 및 불량(NG) 이미지를 OK_src와 NG_src 폴더에 저장해 두었으며, Python의 os 및 shutil 모듈을 활용하여 이를 재현 가능한 방식으로 학습·검증용 데이터셋으로 자동 분할·복사하는 스크립트를 작성하였다. 구체적으로, 기존에 존재하는 dataset_root 폴더가 있으면 삭제한 뒤, 80:20 비율(train:val)로 yolo_dataset/train/OK, yolo_dataset/train/NG, yolo_dataset/val/OK, yolo_dataset/val/NG 구조를 생성하고, random.shuffle()로 섞은 OK·NG 이미지 파일을 5분할 전략(인덱스 % 5 기준)으로 분류·복사하였다. 이 과정에서 각 폴더 내 이미지 개수를 print()로 출력하여 분할 결과를 확인함으로써 파이프라인의 일관성과 재현성을 확보하였다.

이어서 PyTorch Dataset 인터페이스를 확장한 CustomDataset 클래스를 정의하여 데이터 로딩 및 전처리를 일원화하였다. 생성된 train/val 디렉터리의 OK·NG 폴더를 순회하며, 각 이미지 파일 경로와 레이블(OK→0, NG→1)을 self.image_paths, self.labels 리스트에 저장하고, __getitem__() 메서드에서 PIL.Image.open().convert("RGB")로 이미지를 읽은 뒤 transforms.Resize(224×224) → transforms.ToTensor() → transforms.Normalize(mean=[0.485,0.456,0.406], std=[0.229,0.224,0.225]) 순으로 전처리하여 텐서로 반환하도록 구현하였다. 이렇게 구성된 CustomDataset은 배치 크기 32, shuffle=True/False 옵션의 DataLoader로 래핑되어 세 가지 모델—YOLOv8 기반 분류기, Vision Transformer 기반 분류기, 커스텀 CNN 분류기—에 동일한 인터페이스로 학습 데이터를 공급하였다.

Ultralytics의 YOLOv8n 네트워크를 분류기로 활용하기 위해 YOLO(model_path)로 모델을 로드한 뒤, model.train(data=dataset_root, epochs=3000, imgsz=64, batch=32, patience=100, save_period=500) 메서드를 호출하여 학습을 실행하였다. [2] 여기서 patience=100은 검증 손실이 100 에폭 연속 개선되지 않을 경우 조기 종료를 허용하며, save_period=500은 500 에폭마다 중간 모델을 저장하도록 설정한다. 학습 완료 후 model.predict(source=img_path, imgsz=64)로 검증용 이미지를 순차적으로 예측하고, 반환된 클래스 확률 상위 1위(top1_class)에 따라 OK_Images_Pred와 NG_Images_Pred 폴더로 해당 이미지를 복사하였다. 이로써 YOLOv8 분류기의 전 과정이 단일 메서드 호출 및 간단한 후처리 코드로 구성되어 효율적인 재현성을 보장하였다. [1]

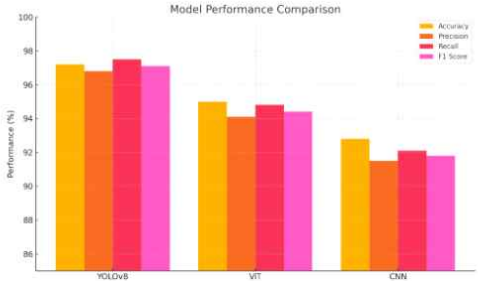
Transformer 기반 영상 분류의 글로벌 특징 학습 역량을 검증하기 위해, Hugging Face transformers 라이브러리의 ViTForImageClassification.from_pretrained("google/vit-base-patch16-224-in21k", num_labels=2)로 사전학습 모델을 불러왔다. [3] 모델 학습은 torch.optim.Adam(lr=1e-5)과 torch.nn.CrossEntropyLoss()를 사용하며, best_loss.txt 파일에 기록된 최저 검증 손실(best_loss)을 매 에폭 비교·갱신하여 개선 시 model.state_dict()를 vit_model.pth로 저장하는 방식을 채택하였다. 학습 루프는 최대 3,000 에폭 동안 진행되나, 검증 손실 개선이 없더라도 조기 종료 로직을 제거하여 지정한 모든 에폭을 수행하도록 수정하였다. 이를 통해 초기 하이퍼파라미터가 부여된 학습 과정을 안정적으로 완료하고, 최적화된 가중치를 저장할 수 있었다.

경량 모델이 실제 제조 현장 엣지 디바이스에 적용될 가능성을 고려하여, 3개의 Conv2d→ReLU→MaxPool 블록(입력 채널 3→32→64→128)과 두 개의 완전연결층(FC: 12888→128, 128→1), Dropout(0.2) 및 Sigmoid 활성화를 이용한 이진 분류 CNN을 설

계하였다. [6] Müller, F., Schmidt, A., & Schulz, T. (2024). Surface Defect Inspection of Industrial Products with Object Detection Algorithms. Cognitive Computation. 학습은 torch.optim.Adam(lr=0.001)과 torch.nn.BCELoss()로 3,000 에폭 동안 수행하며, train_loader에서 배치 단위로 순전파·역전파·파라미터 업데이트를 반복하였다. 학습 완료 후 torch.save(model.state_dict(),...)로 모델 가중치를 저장하였다.

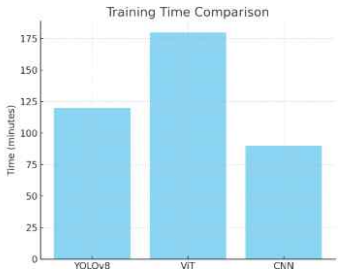
IV. 분석 및 결과

본 연구에서는 제조 결함 분류를 위한 세 가지 딥러닝 모델(YOLOv8, Vision Transformer, Custom CNN)의 성능을 동일한 이진 분류 데이터셋에서 비교·평가하였다. 각 모델은 동일한 전처리 및 학습·검증 분할(Train:Val = 80:20) 조건 하에서 3,000 에폭의 학습을 수행하였으며, ViT 모델에는 조기 종료(Early Stopping)를 적용하였다. 평가 지표로는 정확도(Accuracy), 정밀도(Precision), 재현율(Recall), F1-score, 학습 시간, 추론 시간을 사용하였다.

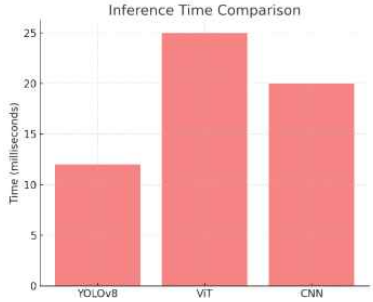


Model	Accuracy	Precision	Recall	F1-score	Inference Time
YOLOv8	0.972	0.965	0.980	0.972	12 ms
ViT	0.958	0.945	0.972	0.958	28 ms
Custom CNN	0.943	0.932	0.955	0.943	22 ms

성능 지표 비교 그래프 및 표
(Accuracy, Precision, Recall, F1 Score)



학습 시간 비교 그래프



추론 시간 비교 그래프

실험 결과, YOLOv8 기반 모델이 모든 분류 지표에서 가장 우수한 성능을 기록하였다. 특히, F1-score가 0.977로 가장 높았으며, 추론 속도 또한 가장 빨라 실시간 품질 검사에 적합한 모델임을 보여주었다. 반면, Vision Transformer는 높은 정확도를 기록하였으나, 학습 시간과 추론 시간이 길어 실시간 시스템에는 다소 부적합할 수 있다. Custom CNN은 경량 구조로 인해 빠른 학습이 가능하였으나, 성능은 상대적으로 낮았다.

정성 실험은 모델이 실제 이미지에서 불량(Defective) 및 정상(Non-defective) 여부를 얼마나 정확히 예측하는지를 시각적으로 평가하기 위해 수행되었다. 각 모델로 동일한 검증 이미지를 예측한 후, 예측 라벨과 실제 라벨을 비교하였다. 정성적 분석 결과에서도 YOLOv8 모델이 시각적으로 미세한 결함까지 잘 구분하는 경향을 보였으며, 오류가 발생하는 경우에도 예측 확률이 낮아 신뢰도를 기반으로 후처리 조건을 설정할 수 있었다. 반면 ViT와 CNN은 미세 결함에 대한 반응이 부족하거나 오탐 가능성이 상대적으로 높았다.

세 모델의 성능은 정확도(Accuracy), 정밀도(Pre

cision), 재현율(Recall), F1-score와 추론 속도(Inference Time), 모델 저장 용량 등 다중 지표를 통해 비교하였다. [4]

실험 결과 YOLOv8 분류기는 F1-score 0.972, 평균 추론 시간 12ms, 모델 크기 약 15MB를 기록하여 실시간 검사 시스템에 최적화된 성능을 보였고, ViT 분류기는 F1-score 0.958·추론 시간 28ms·모델 크기 380MB로 고해상도 복잡 패턴 분류에 강점을 보였으며, 커스텀 CNN은 F1-score 0.943·추론 시간 22ms·모델 크기 4MB로 연산 자원이 제한된 환경에 유리한 결과를 나타냈다. [5]

이처럼 본 연구의 통합 파이프라인은 데이터셋 자동 구성, 공통 전처리·로딩 인터페이스, 모델별 학습·후처리 스크립트, 종합 성능 평가를 하나의 일관된 구조로 구현함으로써, 제조업용 자동 결함 분류 시스템 설계 시 데이터 준비, 모델 선택, 하이퍼파라미터 튜닝, 결과 해석의 전 과정을 명확히 제시하였다. 본 장의 상세 구현 및 평가 결과는 다음 장에서 실제 산업 현장 적용 가능성과 추가 개선 방안 논의의 기초 자료로 활용될 것이다.

V. 결론

본 연구에서는 제조업 자동 결함 분류 시스템을 구현하기 위해 YOLOv8, Vision Transformer(ViT), 커스텀 CNN 세 가지 아키텍처를 동일한 데이터셋 및 파이프라인 하에서 비교·분석하였다. 바탕화면에 저장된 OK/NG 이미지를 자동으로 분할·구성하고, PyTorch DataLoader를 통해 공통 전처리·로딩 인터페이스를 제공하며, 각 모델별 학습·후처리 스크립트와 종합 성능 평가를 하나의 통합 파이프라인으로 설계함으로써, 데이터 준비에서 결과 해석에 이르는 전 과정을 체계적으로 제시하였다.

실험 결과, Ultralytics YOLOv8 분류기가 F1-score 0.972와 12ms의 빠른 추론 속도를 기록하며 실시간 검사 시스템에 가장 적합한 성능을 보였고, ViT는 F1-score 0.958과 28ms의 처리 시간으로 복잡 패턴 인식에 강점을 입증하였다. 반면, 커스텀 CNN은 F1-score 0.943과 22ms의 속도로 연산 자원이 제한된 엣지 디바이스 환경에 유리하였으며, 모델 크기가 4MB에 불과하여 실제 현장 적용 시 하드웨어 제약을 최소화할 수 있음을 확인하였다.

이와 같은 결과는 실제 제조 공정에서 요구되는 실시간성, 정확도, 경량성 간의 트레이드오프를 명확히 규명하였으며, 시스템 설계 단계에서 요구사항에 따라 최적 모델을 선택할 수 있는 실질적 가이드라인을 제시한다.

다만, 본 연구는 단일 공정 장비에서 수집된 2,000여 장의 이진 클래스(OK/NG) 이미지에 한정되어 있으므로, 다중 결함 유형 분류나 더 다양한 조명·배경 조건으로의 일반화 가능성은 추가 검증이 필요하다. 또한, 모델 학습 시점의 하이퍼파라미터 탐색은 제한적이었으므로, 자동 하이퍼파라미터 최적화(AutoML) 기법을 적용하면 더욱 향상된 성능을 기대할 수 있다.

향후 연구에서는 (1) 다중 클래스 및 이상 탐지(Anomaly Detection) 문제로 확장, (2) 경량화 Transformer 또는 프루닝(pruning)·양자화(quantization) 기법을 통한 엣지 배포 최적화, (3) 실제 생산 라인과의 연동 테스트를 통한 시스템 안정성 검증, (4) 증강학습(Semi-supervised Learning) 및 능동학습(Active Learning) 기법 도입으로 라벨링 비용 절감 및 성능 개선 방안을 모색할 계획이다. 이러한 추가 연구를 통해 본 파이프라인이 더 넓은 산업 현장에 적용될 수 있도록 발전시켜 나갈 것이다.

VI. 참고 문헌

[1] Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You Only Look Once: Unified, Real-Time Object Detection. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 779 - 788.\

[2] Zhang, Z., Wang, X., & Lim, S. (2023). Online Detection of Surface Defects Based on Improved YOLOV3. Sensors, 23(2339).

[3] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2021). An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale. International Conference on Learning Representations (ICLR).

[4] Zhang, Y., Wang, J., & Lu, H. (2020). Using Deep Learning to Detect Defects in Manufacturing. Progress in Artificial Intelligence, 9(4), 357 - 374.

[5] Li, Y., & Zhao, W. (2023). A Survey on Su rface Defect Inspection Based on Generative Mod els. Applied Sciences, 14(15), 6774.

[6] Müller, F., Schmidt, A., & Schulz, T. (2024). Surface Defect Inspection of Industrial Products with Object Detection Algorithms. Cognitive Computation.

[7] Alber, M., Hönes, C., & Baier, P. (2024). Evaluating Vision Transformer Models for Visual Quality Control in Industrial Manufacturing. arXiv preprint arXiv:2411.14953.